

1. Wstęp

Projekt wykonany w celu poznawczym. Baza danych została pobrana z oficjalnej strony NASA i zawiera informacje z misji teleskopu Kepler, której głównym celem było poszukiwanie egzoplanet - czyli planet poza Układem Słonecznym. Odkrycia były realizowane metodą tranzytu polegającą na ciągłej obserwacji gwiazd. Jeżeli zauważono cyklicznie przygasanie światła danej gwiazdy, sugerowało to obecność krążącej wokół niej planety.

2. Pojęcia fizyczne

2.1 Baza danych

Baza danych składa się z 50 kolumn z cechami opisującymi potencjalne egzoplanety.

W projekcie głównie skupiono się na dziesięciu z nich:

- a) `koi_disposition` - podział obiektów na zaklasyfikowane jako prawdopodobne planety.
 - `candidate` - obiekty, które prawdopodobnie są planetami
 - `confirmed` - obiekty potwierdzone jako planety
 - `false positive` - obiekty pomyłone z planetami
- b) `koi_period` - czas okrążenia obiektu wokół gwiazdy (liczone w dniach ziemskich)
- c) `koi_depth` - głębokość zaćmienia. Pokazuje jak bardzo spadła jasność gwiazdy gdy obiekt ją zasłonił. **Parts Per Million** (części na milion).
- d) `koi_prad` - wielkość planety (liczone w promieniach Ziemi)
- e) `koi_impact` - opisuje jak blisko *środk*a tarczy gwiazdy przechodzi planeta podczas tranzytu
- f) `koi_insol` - Insolation Flux - opisuje jak dużo energii gwiazdy dociera do planety. (wartość odniesienia = 1 [wartość parametru na Ziemi])
- g) `koi_snr` - Signal to Noise Ratio - poziom sygnału który emitował obiekt
- h) `koi_steff` - temperatura gwiazdy [K]
- i) `koi_slogg` - grawitacja na powierzchni gwiazdy ($\log(g)$) -
- j) `koi_srad` - promień gwiazdy

2.2 Najważniejsze pojęcia fizyczne użyte w projekcie

- a) W celu precyzyjnego wyselekcjonowania planet potencjalnie nadających się do zamieszkania, w raporcie zastosowano kryterium podziału oparte na danych NASA oraz zjawisku tzw. Przerwy Fultona (*Fulton gap*).

Podział planet ze względu na promień (R - promień Ziemi):

- Planety skaliste ($< 1.5R$): Obiekty o wielkości zbliżonej do Ziemi lub nieco większe (Super-Ziemia). Z racji mniejszej masy nie utrzymały gęstych otoczek gazowych, co zwiększa prawdopodobieństwo istnienia stałej powierzchni.
- Przerwa Fultona ($1.5 - 2.0R$): Wyraźny deficyt (brak) odkrytych planet w tym przedziale rozmiarowym. Stanowi ona naturalną granicę ewolucyjną planet.
- Planety gazowe ($> 2.0R$): Obiekty, które ze względu na większą masę szybko przyciągnęły masywną atmosferę złożoną z wodoru i helu, rozrastając się do rozmiarów Sub-Neptunów lub gazowych gigantów.

- b) Obrót synchroniczny- jest to granica wyliczona przez astrofizyków opisująca zjawisko polegające na synchronizacji obrotu planety wokół własnej osi oraz obiegu wokół gwiazdy. Skutkuje ona tym, że dzień na planecie jest równy jej obrotowi wokół planety (1 doba = 1 rok), a co za tym idzie jedna część planety byłaby przez cały rok obrócona do słońca, druga natomiast nigdy by słońca nie doświadczyła.
- c) Insolation Flux (strumień nasłonecznienia) - jest to ilość energii jaką planeta otrzymuje od gwiazdy. Jest to wskaźnik, którego wartość 1.0 oznacza że planeta dostaje dokładnie tyle samo światła co Ziemia
- d) Strefa zdalna do życia - na podstawie zebranych danych, oraz informacji, i praw fizyki, wyznaczono kluczowe parametry które potencjalnie mogą wskazać nową planetę zdolną do życia. Są to :
 - grawitacja na powierzchni gwiazdy w przedziale od 4 - 4.7
 - czas okrążenia obiektu wokół gwiazdy (>30 dni ziemskich)
 - Insolation Flux w przedziale (0.3 do 4)
 - wielkość planety w przedziale od (0.5 - 2)
 - Temperatura na powierzchni planety od 180 K do 310 K

3. Wyniki:

3.1 Python

Język Python (wraz z bibliotekami Pandas, NumPy, Matplotlib oraz Seaborn) został wykorzystany na samym początku projektu w celu przeprowadzenia wstępnej EDA oraz oczyszczenia struktury bazy danych. Usunięto kolumny w których braki wyniosły 100 % - *koi_teq_err1* oraz *koi_teq_err2*. W kolumnie *kepler_name* wykryto znaczącą ilość braków (75%), natomiast świadomie nie zostały one usunięte - pełnią kluczową rolę informacyjną, która pozwala na identyfikację nazw powierzonych planet na końcowym dashboardie. Służył on również do znajdowania korelacji między parametrami astro fizycznymi. Pozwoliło to na szybkie zidentyfikowanie najsilniejszych zależności i zoptymalizować późniejszą pracę w programie Power BI.

3.2 SQL

Ciekawym wynikiem w SQL był fragment opisywany przez ten kod:

```
select kepler_name as `Name`, koi_model_snr as `SNR`, koi_prad as `Size of planet`,  
koi_steff as `Star temperature K`, koi_insol as `Insolation Flux`, koi_teq as  
`Planet temperature`  
from `kepler-497213.Kepler_data.raw_kepler_data`  
where koi_disposition = 'CONFIRMED'  
order by koi_model_snr desc  
limit 10;
```

Pokazuje on obiekty zaklasyfikowane jako Confirmed (istniejąca egzoplaneta) oraz ich kluczowe parametry. Mediana SNR dla planet ze statusem Confirmed wynosiła 30,6 a średnia 87.92, a w tych przypadkach najczęściej wynosiła nawet prawie 6 000, co oznacza że tego typu planety zaburzyły wynik średniej. Planety o takim wysokim emitowanym sygnale cechują się ogromną temperaturą oraz wielkością, co czyni je niezdadnymi do życia.

Wiersz	Name	SNR	Size of planet	Star temperature K	Insolation Flux	Planet temperature	Status
1	Kepler-2 b	5945.9	16.1	6440.0	4148.92	2048.0	CONFIRMED
2	Kepler-1 b	4304.3	13.04	5820.0	761.46	1339.0	CONFIRMED
3	Kepler-13 b	4061.9	21.42	9107.0	37958.27	3559.0	CONFIRMED
4	Kepler-12 b	3535.6	18.05	5953.0	757.65	1338.0	CONFIRMED
5	Kepler-6 b	3003.8	13.06	5640.0	797.62	1356.0	CONFIRMED
6	Kepler-423 b	2833.1	12.73	5561.0	603.57	1265.0	CONFIRMED
7	Kepler-7 b	2590.1	16.66	6036.0	1182.79	1496.0	CONFIRMED

Kolejnym ciekawym fragmentem analizy było stworzenie rankingu 20 obiektów o najsilniejszym sygnale osobno dla każdego rodzaju gwiazdy, z jednoczesnym obliczeniem średniego SNR dla danej grupy. Miało to [m.in](#) na celu porównanie i wskazanie wartości odstających w ramach poszczególnych kategorii.

Kod:

```
with Imp_classification as (  
  
select kepid, kepler_name, koi_disposition, koi_model_snr,  
case  
  when koi_steff between 5200 and 6000 then "Yellow dwarf"  
  when koi_steff between 3500 and 5200 then "Orange dwarf"  
  when koi_steff <= 3500 then "Red dwarf"  
  else "Unkown"  
end as `Star clasification`  
from `kepler-497213.Kepler_data.raw_kepler_data`  
  
) ,
```

```

ranking_raport as(

    select
    kepler_name,
    `Star clasification`,
    koi_model_snr as `SNR`,
    rank() over (partition by `Star clasification` order by koi_model_snr desc) as
planetary_rank,
    round(avg(koi_model_snr) over(partition by `Star clasification`),2) as `Average
SNR`
    from Imp_classification
    where koi_disposition = "CONFIRMED"

)

```

```

SELECT * from ranking_raport
where planetary_rank <= 20
order by `Star clasification` asc;

```

Fragment wyniku:

Wiersz	kepler_name	Star clasification	SNR	planetary_rank	Average SNR
1	Kepler-425 b	Orange dwarf	1549.0	2	62.62
2	Kepler-45 b	Orange dwarf	1341.6	3	62.62
3	Kepler-785 b	Orange dwarf	1252.5	4	62.62
4	Kepler-486 b	Orange dwarf	1126.2	5	62.62
5	Kepler-489 b	Orange dwarf	871.4	6	62.62
6	Kepler-3 b	Orange dwarf	862.3	7	62.62
7	Kepler-695 b	Orange dwarf	568.2	8	62.62
8	Kepler-167 e	Orange dwarf	544.2	9	62.62
9	Kepler-816 b	Orange dwarf	343.4	10	62.62
10	Kepler-94 b	Orange dwarf	312.7	11	62.62

Dzięki temu raportowi widać, które planety drastycznie odstają jakością sygnału od średniej dla swojego typu gwiazdy.

3.3 Power BI

Finalnym etapem projektu było znalezienie planet które potencjalnie mogłyby być uznane jako nadające się do życia. W tym celu stworzono lejek, który za pomocą filtrów (miar napisanych w języku DAX, oraz parametrów opisanych w punkcie 2.2 d)) pozwolił na odnalezienie potencjalnych nowych planet nadających się do życia.

W Tabeli 1. znajduje się planeta o nazwie Kepler -452b, która zasługuje na szczególną uwagę. Charakteryzuje się ona parametrami podobnymi do warunków panujących na Ziemi.

- a) Jej promień wynosi 1.09 promienia Ziemi
- b) Rok na planecie trwa 384 dni
- c) Krąży wokół żółtego karła - gwiazdy typu słonecznego
- d) Grawitacja gwiazdy wynosi 4,58 (grawitacja słońca to 4,44)
- e) Jest ona jednak zimniejsza - temperatura wynosi 220K co odpowiada -53 stopniom Celsjusza.

CANDIDATES FOR NEW EARTH							
kepler_name	Planet Radius (Earth = 1)	Year (Days)	Star Type	Star Gravity	Insolation Flux	Planet Temperature (K)	Status
Kepler-62 f	1,43	267,28	Orange dwarf	4,65	0,44	207,00	CONFIRMED
Kepler-452 b	1,09	384,85	Yellow dwarf	4,58	0,56	220,00	CONFIRMED
Kepler-283 c	1,87	92,75	Orange dwarf	4,68	0,78	240,00	CONFIRMED
Kepler-1544 b	1,69	168,81	Orange dwarf	4,62	0,80	241,00	CONFIRMED
Kepler-442 b	1,30	112,30	Orange dwarf	4,68	0,79	241,00	CONFIRMED
Kepler-62 e	1,72	122,39	Orange dwarf	4,65	1,24	269,00	CONFIRMED
Kepler-69 c	1,73	242,47	Yellow dwarf	4,40	1,59	286,00	CONFIRMED
Kepler-1450 b	1,94	54,51	Orange dwarf	4,67	2,13	308,00	CONFIRMED
Kepler-437 b	1,56	66,65	Orange dwarf	4,63	2,14	308,00	CONFIRMED

